Харилцагч–борлуулагч санал болгох асуудалд SelfGNN загварт ирмэгийн жинг нэгтгэсний нөлөө

Эрдэнэчимэгийн Алтаншагай
Машин оюуны лаборатори, МКУТ, МТЭС
Монгол Улсын Их Сургууль
Монгол Улс, Улаанбаатар хот
22b1num0331@stud.num.edu.mn

Ганболдын Амарсанаа
Машин оюуны лаборатори, МКУТ, МТЭС
Монгол Улсын Их Сургууль
Монгол Улс, Улаанбаатар хот
amarsanaag@num.edu.mn

***Хураангуй*—Энэхүү судалгааанд харилцагч–борлуулагч санал болгох асуудалд SelfGNN суурь загварт ирмэгийн жинг нэгтгэх нь гүйцэтгэлд үзүүлэх нөлөөг судлав. Үүний тулд загварын үндсэн архитектурыг өөрчлөхгүйгээр жинт зэргэлдээ матриц ашиглах хувилбар боловсруулж, үнэлгээ болон гүйлгээний дохионд тохирсон жингийн хувиргалт, нормчлолын аргыг хэрэглэв. Аргыг Yelp болон Finance өгөгдөл дээр туршиж, SelfGNN суурь загвар болон төлөөлөх суурь аргуудтай харьцуулсан. Үр дүнд нь ирмэгийн жинтэй SelfGNN хувилбар нь хоёр өгөгдөл дээр хоёуланд нь HR@10 болон NDCG@10 хэмжүүрээр хамгийн өндөр үзүүлэлтэд хүрсэн. SelfGNN суурь загвартай харьцуулахад Yelp дээр HR@10 2.22%-аар, NDCG@10 3.18%-аар, Finance дээр HR@10 3.96%-аар, NDCG@10 4.33%-аар тус тус өсөв. Мөн харилцагчийн бүлгийн шинжилгээгээр ирмэгийн жингийн нөлөө нь харилцагчийн идэвхийн түвшнээс хамааран ялгаатай бөгөөд Finance өгөгдөлд бага болон дунд идэвхтэй бүлгүүдэд илүү тод ажиглагдав. Эдгээр үр дүн нь зөв нормчилсон ирмэгийн жин нь SelfGNN-д нэмэлт дохио өгч, харилцагч–борлуулагч санал болгох чанарыг сайжруулж болохыг харуулж байна.**

***Түлхүүр үгс*—SelfGNN, граф нейрал сүлжээ, ирмэгийн жин, санал болгох систем, борлуулагч санал болгох**

I. Танилцуулга

Санал болгох системүүд харилцагчийн зан төлөвт суурилан дараагийн боломжит зүйлийг таамаглахад чиглэсэн байдаг. Борлуулагч санал болгох нь харилцагчийн худалдан авалтын түүх дээр үндэслэн харилцагчид дараа нь үйлчлэх магадлалтай боломжит борлуулагчийг олж танилцуулах зорилготой. Уламжлалт объект санал болгох даалгавраас ялгаатай нь харилцагч–борлуулагч санал болгох орчинд өгөгдлийн сийрэгжилт, цөөн тохиолдол бүхий борлуулагчдын давамгайлал, цаг хугацааны динамик өөрчлөлт, харилцааны хүчийг загварт шингээх шаардлагатай зэрэг нэмэлт сорилтууд үүсдэг.

Граф нейрал сүлжээ (GNN) нь харилцагч–объектын харилцааг хоёр хэсэгт граф хэлбэрээр дүрсэлж, хөршийн өндөр эрэмбийн дохиог нэгтгэдэг тул санал болгох системд өргөн ашиглагдаж байна [1]. LightGCN [2] зэрэг энгийн тархалтын загварууд хамтын шүүлтийн дохиог үр дүнтэй сурдаг бол SASRec [3], BERT4Rec [4] зэрэг дараалын аргууд харилцагчийн цаг хугацааны зан төлөвийг онцолдог. SelfGNN [5] нь эдгээр хоёр чиглэлийг нэгтгэн, богино хугацааны граф кодчилол, урт хугацааны дараалын загварчлал, SAL өөрийгөө хянасан сургалтаар дараалалд суурилсан санал болгох гүйцэтгэлийг сайжруулсан.

Гэсэн хэдий ч SelfGNN харилцагч–борлуулагчийн холбоог хоёртын утгаар авч үздэг. Бодит домэйнд нэг одтой ба таван одтой үнэлгээ, бага ба өндөр дүнтэй гүйлгээ, нэг удаагийн ба давтамжтай харилцаа ижил утгатай байх албагүй. Иймээс энэхүү судалгааны зорилго нь SelfGNN загварт ирмэгийн жинг нэгтгэх нь борлуулагч санал болгох системийн гүйцэтгэлд ямар нөлөө үзүүлэхийг тодорхойлох явдал юм.

Судалгааны гол хувь нэмрийг дараах байдлаар тодорхойлж болно.

- SelfGNN загварын үндсэн архитектурыг өөрчлөхгүйгээр ирмэгийн жинг нэгтгэн ашиглах хэрэгжүүлэлтийн хувилбарыг санал болгов.
- Yelp болон Finance өгөгдлийн бүрдэл тус бүрд харилцааны хүчийг илэрхийлэх хэмжигдэхүүнд тохирсон нормчлолын аргыг хэрэглэв.
- SelfGNN суурь загвар, ирмэгийн жинт SelfGNN хувилбар болон бусад суурь загваруудыг нэгийг тусгаарлан үнэлэх (leave-one-out) аргаар харьцуулж, ирмэгийн жингийн нөлөөллийн боломж ба хязгаарлалтыг тоон үр дүнгээр шинжилж харуулав.

II. Холбоотой ажил

A. Графт суурилсан санал болгох систем

Матриц задлалын аргаас эхэлсэн хамтын шүүлт нь BPR-MF [6] болон GNN-д суурилсан загварууд руу хөгжсөн. GNN аргууд харилцагч–объектын граф дахь хөршийн мэдээллийг давхарлан нэгтгэж, зөвхөн шууд харилцаа бус өндөр эрэмбийн хамаарлыг сурдаг. LightGCN [2] нь шинжийн хувиргалт болон шугаман бус идэвхжүүлэлтийг хялбаршуулснаар санал болгох системд граф тархалтын үндсэн дохио хангалттай хүчтэй болохыг харуулсан.

B. Дараалал ба SelfGNN

Дараалалд суурилсан санал болгох аргууд харилцагчийн харилцааны цаг хугацааны дараалыг ашигладаг. SASRec [3] шалтгаант self-attention, BERT4Rec [4] масктай объект таамаглал ашигладаг. SelfGNN [5] нь харилцагч–объектын харилцааг цагийн интервалуудын богино хугацааны граф болгон хувааж, эдгээр графаас сурсан эмбеддингийг дараалын attention механизмтай нэгтгэдэг. SAL механизм нь богино хугацааны граф дахь шуугианыг харилцагчийн урт хугацааны төлөөлөлтэй харьцуулан бууруулдаг.

C. Ирмэгийн шинж ба жин

Зарим хэрэглээний орчинд ирмэг нь зөвхөн холбоо оршин байгааг илэрхийлэхээс гадна илүү баялаг мэдээлэл агуулдаг. GC-MC [9] нь граф дээр суурилсан матриц нөхөлтийн хүрээнд үнэлгээний түвшинг ирмэгийн мэдээлэл болгон ашигласан. Мөн банкны гүйлгээний чиглэлийн судалгаанууд ирмэгийн жин болон гүйлгээтэй холбоотой баялаг шинжүүдийг ашиглах нь холбоос таамаглалын гүйцэтгэлийг сайжруулж болохыг харуулсан [10], [11]. Гэсэн хэдий ч ирмэгийн мэдээллийг шууд нэгтгэх нь үргэлж гүйцэтгэлийг сайжруулна гэсэн баталгаа байхгүй. Тухайлбал, үнэлгээ өндөр утгад төвлөрөх, гүйлгээний дүнгийн тархалт ихэнхдээ бага утгад төвлөрч цөөн тооны маш өндөр дүнгээр давамгайлах, мөн нормчлолын явцад утгын муж агших зэрэг нь GNN-ийн мессеж дамжуулалтын үед ялгаатай мэдээллийг хадгалах чадварыг сулруулж болзошгүй.

III. Судалгааны асуулт

Энэхүү ажил нь дараах судалгааны асуултуудад хариулна.

- **CA1**: Ирмэгийн жинг ашиглах нь SelfGNN суурь загвартай харьцуулахад эхний K байрлал дахь санал болголтын чанарыг сайжруулах уу?
- **CA2**: Ирмэгийн жинтэй SelfGNN загвар нь Popularity, BPRMF, LightGCN, SASRec, BERT4Rec зэрэг суурь аргуудтай харьцуулахад ямар түвшний гүйцэтгэл үзүүлэх вэ?
- **CA3**: Ажиглагдсан нөлөө нь харилцагчийн идэвхийн сегментүүд болон туршилтын давталтуудын хооронд тогтвортой байна уу?

IV. Арга зүй

A. Бодлогын томьёолол

Харилцагчдын олонлогийг $\mathcal{U} = \{u_1, \ldots, u_I\}$, борлуулагчдын олонлогийг $\mathcal{M} = \{m_1, \ldots, m_J\}$ гэж тэмдэглэе. Хугацааны мужийг T интервалд хувааж, t-р интервал дахь харилцан үйлчлэлийг $\mathbf{A}_t \in \mathbb{R}^{I \times J}$ матрицаар илэрхийлнэ. SelfGNN-ийн суурь хувилбарт $\mathbf{A}_{t,ij} = 1$ бол u_i харилцагч m_j борлуулагчтай тухайн интервалд дор хаяж нэг удаа харилцсан, үгүй бол 0 байна. Бидний зорилго нь харилцагчийн сургалтын дараалалд тулгуурлан тестийн интервал дахь бодит дараагийн борлуулагчийг тухайн харилцагчийн

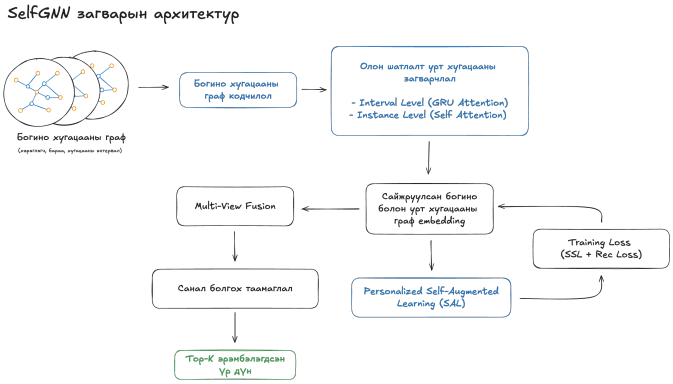

Зураг 1. SelfGNN загварын ерөнхий архитектур [5]. Загвар нь богино хугацааны граф кодчилол, урт хугацааны дараалал загварчлал, SAL механизм гэсэн гурван үндсэн бүрдэлтэй.

өмнө нь харилцаагүй борлуулагчдаас бүрдсэн сөрөг нэр дэвшигчдийн дундаас эрэмбэлэх явдал юм.

B. SelfGNN суурь загвар

SelfGNN [5] нь дараалалд суурилсан санал болгох системд зориулсан өөрийгөө хянасан граф нейрал сүлжээ бөгөөд Зураг 1-д үзүүлсэн гурван үндсэн бүрдэлтэй.

(1) Богино хугацааны граф кодчилол. Хугацааны интервал бүрд байгуулагдсан харилцааны граф дээр LightGCN-тэй төстэй граф тархаалтыг ашиглан харилцагч болон борлуулагчийн богино хугацааны эмбеддингүүдийг сурна.

(2) Урт хугацааны дараалал загварчлал. Интервал түвшинд GRU болон self-attention ашиглан хугацааны хамаарлыг сурна. Инстанц түвшинд харилцагчийн үйлдлийн дараалыг self-attention-аар загварчилна.

(3) Self-Augmented Learning (SAL). Харилцагчийн борлуулагчтай харилцсан дараалыг self-attention-аар кодчилж, SAL алдагдлын тусламжтайгаар богино хугацааны граф дахь шуугианы нөлөөг бууруулна.

C. Жинт графын нормчлол

SelfGNN-ийн суурь хувилбарт ашигладаг хоёртын зэргэлдээ матрицын оронд $\mathbf{W}_t$ жинт зэргэлдээ матрицыг хэрэглэв. Хэрэв u_i харилцагч ба m_j борлуулагчийн хооронд t-р интервалд харилцаа ажиглагдсан бол $\mathbf{W}_{t,ij} = w_{t,ij}$, эсрэг тохиолдолд 0 байна. Дараа нь GCN-ийн мессеж дамжуулалттай нийцүүлэхийн тулд дараах тэгш хэмт нормчлолыг хэрэглэв.

$$\widetilde{\mathbf{W}}_{t,ij} = \frac{w_{t,ij}}{\sqrt{\sum_{j'} w_{t,ij'}}\sqrt{\sum_{i'} w_{t,i'j}}}. \tag{1}$$

Энэхүү нормчлол нь харилцагч, борлуулагчийн холбооны тооны ялгаанаас үүдэх нөлөөг тэнцвэржүүлнэ. Хэрэв бүх ирмэгийн жин 1 байвал энэ нь LightGCN-ийн суурь нормчлолтой адил болно. Хэрэгжүүлэлтийн түвшинд тухайн ирмэгийн жин тодорхойгүй тохиолдолд хэт бага эсвэл хэт их жин оноохоос зайлсхийх зорилгоор нормчилсон

мужийн дундаж утгад харгалзах 0.5-ыг анхдагч утгаар сонгов.

D. Ирмэгийн жингийн хувиргалт

Ирмэгийн жин нь өгөгдлийн төрлөөс хамааран өөр өөр анхдагч дохионоос тооцогдоно. Үнэлгээнд суурилсан тохиолдолд нэг харилцагч–борлуулагч хосын дундаж үнэлгээг шууд ашиглах нь хангалттай ялгарал өгөхгүй байж болзошгүй. Иймээс n_{ij}-ийг тухайн хосын ажиглалтын тоо, $\bar{r}_{ij}$-ийг дундаж үнэлгээ, μ-г нийт дундаж үнэлгээ гэж тэмдэглэн Bayesian shrinkage аргаар засварласан үнэлгээг дараах байдлаар тодорхойлов.

$$r^*_{ij} = \frac{n_{ij}\bar{r}_{ij} + c\mu}{n_{ij} + c}, \quad c = 10. \tag{2}$$

Дараа нь r^*_{ij}-ийг min–max нормчлолоор $[0, 1]$ мужид шилжүүлж, w_{ij} жин болгон ашиглав.

Харин гүйлгээний дүнд суурилсан тохиолдолд түүхий дүнг шууд ашиглахад цөөн тооны маш өндөр утга бусдаасаа хэт ялгарах боломжтой. Иймээс нэг харилцагч–борлуулагч хосын дундаж абсолют гүйлгээний дүнг a_{ij} гэж тэмдэглэн, эхлээд $\log(1 + a_{ij})$ хувиргалт хийж, дараа нь эрэмбэд суурилсан жин болгон хөрвүүлэв.

$$w_{ij} = \frac{\mathrm{rank}(\log(1 + a_{ij})) + 1}{N + 1}, \tag{3}$$

энд N нь жин өгөгдсөн ирмэгийн нийт тоо. Энэхүү хувиргалт нь абсолют хэмжээг бүрэн хадгалахгүй боловч харьцангуй дараалаллыг хадгалж, жингүүдийг тогтвортой мужид байрлуулах давуу талтай.

E. Сургалтын алгоритм

Алгоритм 1-д нийт сургалтын үйл явцыг харуулна.

Ирмэгийн жинг ашиглахад загварын параметрийн тоо нэмэгдэхгүй. Нэг epoch дахь граф дамжуулалтын үндсэн тооцооллын төвөгшил нь $O(TL|\mathcal{E}|)$ хэвээр байна. Энд L нь GNN давхаргын тоо, $|\mathcal{E}|$ нь сургалтад ашиглагдсан ирмэгийн тоо юм. Жинт нормчлолын нэмэлт зардал нь сийрэг зэргэлдээ матрицыг байгуулах үеийн нэг удаагийн тооцооллоор хязгаарлагдана.

Алгоритм 1 Ирмэгийн жинтэй SelfGNN-ийн сургалт

Оролт: Харилцагч–борлуулагчийн хугацааны дараалсан харилцаа, ирмэгийн жинг тооцоход шаардлагатай мэдээлэл

Гаралт: Сурсан SelfGNN-ийн параметрүүд

```
Өгөгдлийг нэгийг тусгаарлан үнэлэх зарчмаар сургалт, баталгаажуулалт, тестийн хэсэгт хуваана
Сургалтын хэсгээс T богино хугацааны интервалын граф байгуулна
Өгөгдлийн төрөлд тохирсон хувиргалтаар w_ij жинг тооцно
for интервал t = 1, ..., T do
    W̃_t = D_u^{-1/2} W_t D_m^{-1/2} жинт нормчилсон матрицыг байгуулна
end for
for epoch бүр do
    Жинт граф бүр дээр богино хугацааны GNN төлөөллүүдийг сурна
    LSTM болон self-attention ашиглан цаг хугацааны болон дараалын эмбеддингүүдийг үүсгэнэ
    Эрэмбэлэлтийн алдагдал, L_2 регуляризаци, SAL алдагдлыг нэгтгэн параметрүүдийг шинэчилнэ
    Баталгаажуулалтын NDCG@10 сайжирвал загварын төлөвийг хадгална
end for
Буцаах: Баталгаажуулалтын хамгийн сайн үзүүлэлттэй загварын төлөв
```

V. Туршилтын тохиргоо

A. Өгөгдөл боловсруулах

Yelp нь үнэлгээ болон сэтгэгдэл агуулсан олон нийтийн өгөгдөл бөгөөд Finance нь Монголын нэг арилжааны банкны гүйлгээний өгөгдөлд үндэслэн бэлтгэсэн харилцагч–борлуулагчийн өгөгдөл юм. Хоёр өгөгдлийн бүрдэлд хоёуланд нь хамгийн сүүлийн хоёр жилийн харилцааг хадгалж, $k = 5$ k-core шүүлт хэрэглэв. Үүний дараа харилцагч бүрийн хамгийн сүүлийн харилцааг тест, түүнээс өмнөх харилцааг баталгаажуулалт, үлдсэн харилцааг сургалтын хэсэгт хуваав. Мөн тест болон баталгаажуулалтын харилцагчдыг сургалтын үеийн идэвхийн түвшнээр нь бага, дунд, өндөр гэсэн гурван бүлэгт ангилан, бүлэг тус бүрээс тэнцвэртэйгээр сонгов.

Хүснэгт I
Туршилтад ашигласан өгөгдлийн статистик

Үзүүлэлт	Yelp	Finance
Хамарсан хугацаа	Сүүлийн 2 жил	Сүүлийн 2 жил
Харилцагчийн тоо	26,668	1,210
Борлуулагчийн тоо	19,307	17,377
Өгөгдлийн нягтрал (%)	0.0584	0.6490
Сургалтын харилцан үйлчлэлийн тоо	290,891	2,747,386
Давтагдаагүй сургалтын хосын тоо	281,673	136,415
Тестийн харилцагчийн тоо	9,999	1,210
Баталгаажуулалтын харилцагчийн тоо	9,999	1,210
Нэг харилцагчид ногдох сөрөг дээж	999	999
Хугацааны интервалын тоо T	8	8
Ирмэгийн жинг тооцох анхдагч дохио	Одны үнэлгээ	Гүйлгээний дүн

B. Суурь аргууд ба гиперпараметрийн сонголт

SelfGNN суурь загвар болон ирмэгийн жинтэй SelfGNN хувилбарыг Popularity, BPRMF, LightGCN, SASRec, BERT4Rec зэрэг суурь аргуудтай харьцуулсан. Нейрон сүлжээнд суурилсан бүх аргад эмбеддингийн хэмжээсийг 64-т тогтоов. SelfGNN загварт багцын хэмжээг 512, суралцах хурдыг 10^{-3}, суралцах хурдын бууралтын коэффициентыг 0.96, GNN давхаргын тоог 3, self-attention давхаргын тоог 2, self-attention-ийн толгойн тоог 16, хамгийн их дараалын уртыг 200, хадгалах хувийг 0.5, L_2 регуляризацийг 10^{-2}, SAL алдагдлын жинг 10^{-7}, нийт epoch-ийн тоог 150, early stopping шалгуурын patience-ийг 20-оор тохируулсан. Үнэлгээ хийх бүрд HR@10, HR@20,

Хүснэгт II
Суурь аргууд болон SelfGNN хувилбаруудын тестийн гүйцэтгэл. Багана тус бүрийн хамгийн өндөр утгыг тодруулав.

Арга	**Yelp**		**Finance**	
	HR@10	NDCG@10	HR@10	NDCG@10
Popularity	0.0690	0.0360	0.6901	0.5596
BPRMF	0.2128	0.1213	0.6868	0.5156
LightGCN	0.2746	0.1456	0.6661	0.5079
SASRec	0.0650	0.0337	0.6818	0.5590
BERT4Rec	0.0650	0.0339	0.6810	0.5541
SelfGNN суурь	0.2926	0.1535	0.6884	0.5738
SelfGNN + ирмэгийн жин	**0.2991**	**0.1583**	**0.7157**	**0.5986**

Хүснэгт III
Yelp болон Finance өгөгдлийн баталгаажуулалтын гүйцэтгэл. Багана тус бүрийн хамгийн өндөр утгыг тодруулав.

Өгөгдөл	**Хувилбар**	**HR@10**	**NDCG@10**	**HR@20**	**NDCG@20**
Yelp	SelfGNN суурь	0.3096	0.1653	0.4524	0.2013
Yelp	SelfGNN + ирмэгийн жин	**0.3147**	**0.1696**	**0.4539**	**0.2047**
Finance	SelfGNN суурь	0.6884	0.5688	0.7149	0.5755
Finance	SelfGNN + ирмэгийн жин	**0.7041**	**0.5825**	**0.7372**	**0.5910**

NDCG@10, NDCG@20 хэмжүүрүүдийг тооцсон.

VI. Үр дүн ба хэлэлцүүлэг

A. Суурь аргуудын харьцуулалт

Хүснэгт II-д суурь аргууд болон SelfGNN хувилбаруудын тестийн гүйцэтгэлийг үзүүлэв. Yelp болон Finance өгөгдлийн бүрдэл хоёуланд нь SelfGNN + ирмэгийн жин хувилбар нь HR@10 болон NDCG@10 хэмжүүрээр хамгийн өндөр үзүүлэлтэд хүрсэн. Yelp дээр LightGCN нь суурь графт аргуудын дундаас хамгийн сайн үр дүн үзүүлсэн бол Finance дээр Popularity арга HR@10 хэмжүүрээр харьцангуй өндөр байсан ч NDCG@10 хэмжүүрээр SelfGNN-ийн хоёр хувилбар илүү сайн байв. Энэ нь Finance өгөгдөлд түгээмэл борлуулагчдыг санал болгох энгийн стратеги тодорхой хэмжээнд үр дүнтэй байж болох ч эрэмбийн чанарын хувьд SelfGNN загварууд давуу байгааг харуулж байна.

B. Баталгаажуулалтын үр дүн

Yelp болон Finance өгөгдлийн бүрдэл тус бүр дээр баталгаажуулалтын гүйцэтгэлийг үнэлэв. Хүснэгт III-д хамгийн сайн загварын төлөв сонгоход ашигласан баталгаажуулалтын хэмжүүрүүдийг үзүүлэв. Yelp өгөгдөл дээр SelfGNN + ирмэгийн жин хувилбар нь HR@10 хэмжүүрийг 0.3096-аас 0.3147, NDCG@10 хэмжүүрийг 0.1653-аас 0.1696 болгон өсгөсөн. Finance өгөгдөл дээр мөн HR@10 нь 0.6884-өөс 0.7041, NDCG@10 нь 0.5688-аас 0.5825 болж нэмэгдсэн. Иймээс ирмэгийн жинг ашигласнаар бий болсон сайжруулалт нь зөвхөн тестийн үр дүнд бус, баталгаажуулалтын үр дүнд мөн тогтвортой ажиглагдсан гэж үзэж болно.

C. Ирмэгийн жингийн шууд нөлөө

Хүснэгт IV-д SelfGNN суурь загвар болон SelfGNN + ирмэгийн жин хувилбарын тестийн гүйцэтгэлийг шууд харьцуулан үзүүлэв. Yelp болон Finance өгөгдөл дээр хоёр хувилбарыг ижил $T = 8$ тохиргоонд үнэлсэн тул ажиглагдсан ялгаа нь үндсэндээ ирмэгийн жинг нэгтгэсний нөлөөг илэрхийлнэ. Yelp дээр HR@10 0.2926-аас 0.2991, NDCG@10 0.1535-аас 0.1583 болж, Finance дээр HR@10 0.6884-өөс 0.7157, NDCG@10 0.5738-аас 0.5986 болж тус тус өссөн. Энэ нь ирмэгийн жинг ашигласнаар хоёр өгөгдөл дээр хоёуланд нь эерэг өөрчлөлт ажиглагдаж байгааг харуулж байна.

Хүснэгт IV
SelfGNN суурь загвар ба SelfGNN + ирмэгийн жин хувилбарын шууд харьцуулалт.

Өгөгдөл	**Хувилбар**	**HR@10**	**NDCG@10**	**NDCG@10-ийн өөрчлөлт**
Yelp	SelfGNN суурь	0.2926	0.1535	–
Yelp	SelfGNN + ирмэгийн жин	**0.2991**	**0.1583**	+3.18%
Finance	SelfGNN суурь	0.6884	0.5738	–
Finance	SelfGNN + ирмэгийн жин	**0.7157**	**0.5986**	+4.33%

Зураг 2-д Yelp болон Finance өгөгдлийн баталгаажуулалтын муруйг үзүүлэв. Finance өгөгдөл дээр SelfGNN + ирмэгийн жин хувилбар нь ойролцоогоор 42-р epoch-оос хойш HR@10 болон NDCG@10 хэмжүүрээр суурь хувилбараас тогтвортой өндөр үзүүлэлттэй байна. Yelp өгөгдөл дээр хоёр хувилбарын ялгаа харьцангуй бага боловч сургалтын төгсгөлд SelfGNN + ирмэгийн жин хувилбарын баталгаажуулалтын HR@10 болон NDCG@10 нь суурь хувилбараас өндөр байна. Иймээс ирмэгийн жин нь зөвхөн эцсийн тестийн үр дүнд бус, сургалтын явц дахь баталгаажуулалтын гүйцэтгэлд мөн нэмэлт дохио өгч байгааг харуулж байна.

Сургалтын тогтвортой байдлыг алдагдлын муруйгаар давхар үнэлэв. Зураг 3-д хоёр өгөгдөл дээр SelfGNN суурь загвар болон SelfGNN + ирмэгийн жин хувилбарын сургалтын алдагдал ерөнхийдөө тогтвортой буурч байгааг харуулав. Finance өгөгдөл дээр алдагдлын эхний утга Yelp-ээс өндөр байгаа нь өгөгдлийн хэмжээ, нягтралын ялгаатай холбоотой байж болох юм. Ирмэгийн жинтэй хувилбар нь нэмэлт параметр оруулахгүй боловч суурь хувилбартай адил тогтвортой сурч байгааг ажиглав.

D. Харилцагчийн бүлгээр хийсэн шинжилгээ

Хүснэгт V-д Yelp болон Finance өгөгдлийн бага, дунд, өндөр идэвхтэй харилцагчдын бүлэг тус бүр дэх тестийн үр дүнг үзүүлэв. Yelp дээр SelfGNN + ирмэгийн жин хувилбар нь бүх бүлэгт HR@10 болон NDCG@10-ийг өсгөсөн бөгөөд дунд бүлэгт өсөлт хамгийн тод ажиглагдав. Finance дээр мөн бүх бүлэгт сайжруулалт эерэг байсан боловч HR@10-ийн өсөлт бага болон дунд идэвхтэй харилцагчдын бүлэгт илүү их байв. Өндөр идэвхтэй бүлэгт HR@10-ийн өсөлт харьцангуй бага байсан ч NDCG@10 эергээр өссөн хэвээр байна. Энэ нь суурь графын бүтэц өндөр идэвхтэй харилцагчдад аль хэдийн хангалттай дохио агуулж байж болох ч ирмэгийн жин нь эрэмбийн чанарт нэмэлт мэдээлэл өгч байгааг харуулна.

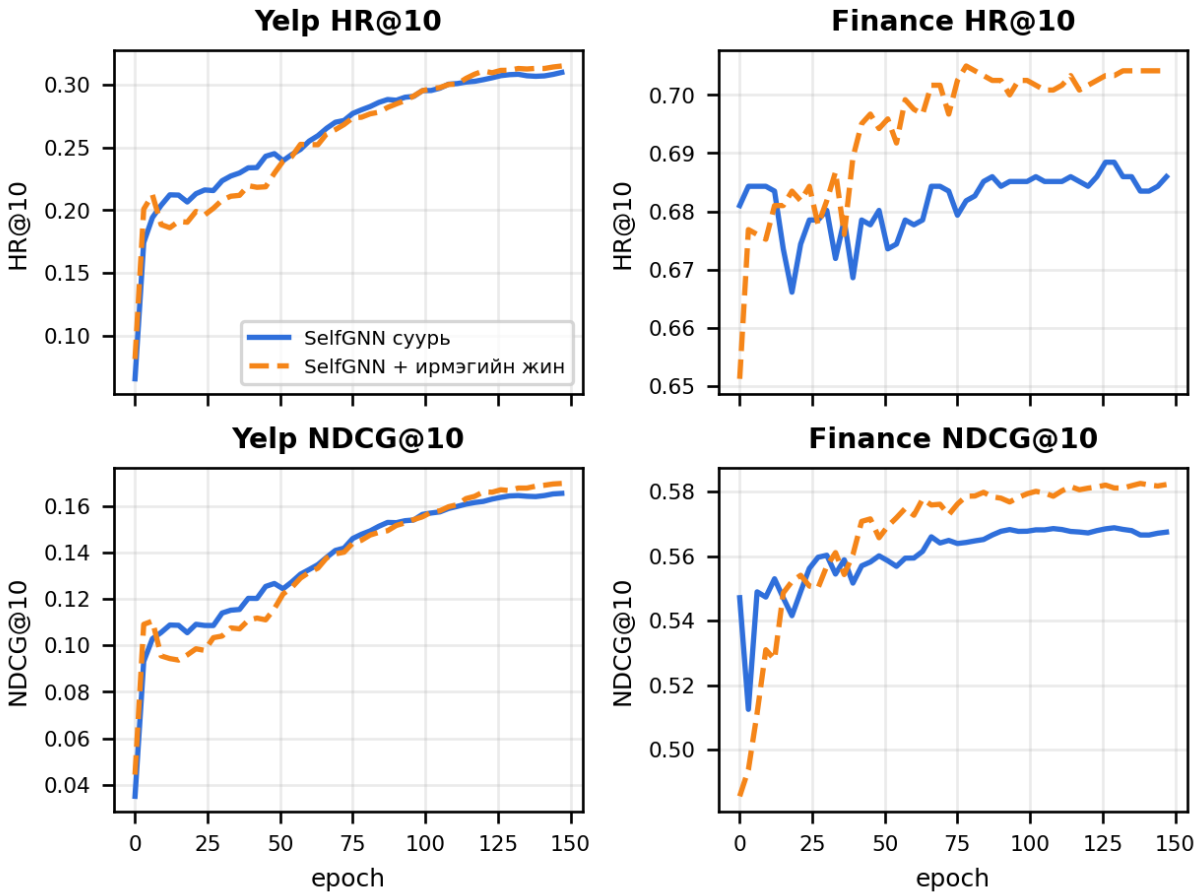

Зураг 2. Yelp болон Finance өгөгдлийн баталгаажуулалтын HR@10, NDCG@10 муруй. SelfGNN + ирмэгийн жин хувилбар нь хоёр өгөгдөл дээр сургалтын төгсгөлд суурь хувилбараас өндөр баталгаажуулалтын үзүүлэлттэй байна.

Хүснэгт V
Yelp болон Finance өгөгдлийн харилцагчийн бүлгүүд дэх SelfGNN суурь ба SelfGNN + ирмэгийн жин хувилбарын тестийн үр дүн. Бүлэг бүрийн харилцан үйлчлэлийн тоон босгыг хамт үзүүлэв. Бүлэг тус бүрийн хамгийн өндөр утгыг доогуур зураасаар тэмдэглэв.

Өгөгдөл	Бүлэг	Харилцан үйлчлэлийн тоо	HR@10		NDCG@10	
			Суурь	+ Ирмэгийн жин	Суурь	+ Ирмэгийн жин
Yelp	Бага	≤ 6	0.2832	0.2853	0.1481	0.1514
Yelp	Дунд	7-10	0.2871	0.2973	0.1510	0.1588
Yelp	Өндөр	> 10	0.3075	0.3147	0.1612	0.1648
Finance	Бага	≤ 1691	0.6658	0.6955	0.5330	0.5538
Finance	Дунд	1692-2454	0.6427	0.6849	0.5371	0.5708
Finance	Өндөр	> 2454	0.7568	0.7667	0.6515	0.6714

E. Судалгааны асуултуудын хариу

CA1. Ирмэгийн жинг ашиглах нь SelfGNN-ийн гүйцэтгэлийг сайжруулж байна уу? Ерөнхийдөө тийм. Yelp болон Finance өгөгдөл дээр SelfGNN + ирмэгийн жин хувилбар нь SelfGNN суурь загвараас HR@10 болон NDCG@10 хэмжүүрээр өндөр үзүүлэлттэй байв. Энэ нь ирмэгийн жин нь нэмэлт дохио өгч, гүйцэтгэлийг сайжруулах боломжтойг харуулна.

CA2. Суурь аргуудтай харьцуулахад ямар түвшинд байна вэ? SelfGNN + ирмэгийн жин хувилбар нь хоёр өгөгдөл дээр хоёуланд нь хамгийн өндөр HR@10 болон NDCG@10 үзүүлэлтэд хүрсэн. Иймээс ирмэгийн жинг нэгтгэх нь зөвхөн суурь SelfGNN-ийг бус, бусад суурь аргуудтай харьцуулахад ч давуу байж болохыг харуулж байна.

CA3. Нөлөө бүх харилцагчийн бүлэгт адил байна уу? Үгүй. Yelp дээр бүх бүлэгт эерэг өөрчлөлт ажиглагдсан бол Finance дээр бага болон дунд бүлэгт өсөлт илүү ажиглагдсан байв. Энэ нь ирмэгийн жингийн нөлөө харилцагчийн идэвхийн түвшнээс хамааран өөр байгааг харуулна.

VII. Хязгаарлалт

Энэ судалгаа хэд хэдэн хязгаарлалттай. Нэгдүгээрт, ирмэгийн жинд ашигласан дохио нь харилцааны чанарыг шууд, бүрэн илэрхийлэхгүй байж болно. Одон үнэлгээ нь харилцагчийн сэтгэл ханамжийг илтгэх боловч өндөр утгад төвлөрөх хандлагатай, харин гүйлгээний дүн өндөр

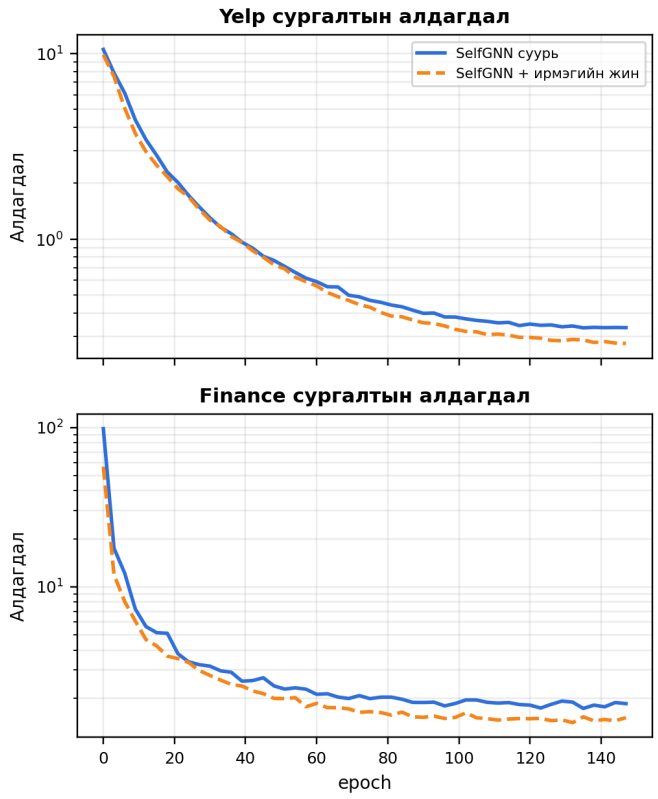

Зураг 3. Yelp болон Finance өгөгдөл дээрх сургалтын алдагдлын муруй, лог хуваарь.

байх нь заавал илүү давуу хэрэглээг илэрхийлэхгүй. Хоёрдугаарт, үнэлгээг 999 түүвэрлэсэн сөрөг жишээн дээр хийсэн тул үр дүнг бүх каталог дэх эрэмбэлэлтийн үнэмлэхүй чанартай шууд адилтгах боломжгүй. Гуравдугаарт, ирмэгийн жинтэй хувилбарт тусгай гиперпараметрийн нарийвчилсан тохируулга хийгдээгүй бөгөөд нормчлолын өөр хувилбаруудыг системтэйгээр салангид туршилтаар шалгаагүй.

VIII. Дүгнэлт

Энэхүү ажлаар SelfGNN загварт ирмэгийн жинг нэгтгэн ашиглах нь харилцагч–борлуулагч санал болгох чанарт хэрхэн нөлөөлөхийг судлав. Үүний тулд SelfGNN-ийн үндсэн архитектурыг өөрчлөхгүйгээр жинт зэргэлдээ матриц ашиглах хэрэгжүүлэлтийн хувилбар боловсруулж, үнэлгээ болон гүйлгээний дүнд суурилсан хоёр төрлийн дохионд тохирсон жингийн хувиргалт ба нормчлолын аргыг хэрэглэв. Yelp болон Finance өгөгдөл дээр хийсэн туршилтаар SelfGNN + ирмэгийн жин хувилбар нь SelfGNN суурь загвар болон бусад суурь аргуудтай харьцуулахад HR@10, NDCG@10 хэмжүүрээр хамгийн өндөр үзүүлэлт үзүүлсэн. Мөн бүлгийн шинжилгээнээс ирмэгийн жингийн нөлөө бүх харилцагчид ижил бус, харин идэвхийн түвшнээс хамааран өөр байгааг ажиглав. Ялангуяа өгөгдөл харьцангуй бага бүлгүүдэд ирмэгийн жин нь харилцааны чанарыг ялгах нэмэлт дохио болж байна.

Иймээс энэхүү судалгааны үндсэн дүгнэлт нь ирмэгийн жинг зөв төлөвлөж, зохистой нормчилсон тохиолдолд SelfGNN-д ашигтай нэмэлт мэдээлэл өгч, харилцагч–борлуулагч санал болгох системийн эрэмбэлэлтийн чанарыг сайжруулж чадна гэсэн үр дүн юм. Цаашдын ажилд ирмэгийн жинг тооцох илүү баялаг дохио, өөр нормчлолын хувилбар, мөн гиперпараметрийн системтэй тохируулгыг судлах нь зүйтэй.

Зүүлт

[1] C. Gao et al., ``A Survey of Graph Neural Networks for Recommender Systems: Challenges, Methods, and Directions," *ACM Transactions on Recommender Systems*, vol. 1, no. 1, Article 3, 2023. DOI: 10.1145/3568022.

[2] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, ``LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation," in *Proceedings of SIGIR*, 2020.

[3] W.-C. Kang and J. McAuley, ``Self-Attentive Sequential Recommendation," in *Proceedings of IEEE ICDM*, 2018.

[4] F. Sun, J. Liu, J. Wu, C. Pei, X. Lin, W. Ou, and P. Jiang, ``BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer," in *Proceedings of ACM CIKM*, 2019.

[5] Y. Liu, L. Xia, and C. Huang, ``SelfGNN: Self-Supervised Graph Neural Networks for Sequential Recommendation," in *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR'24)*, Washington, DC, USA, July 2024, pp. 1609–1618. DOI: 10.1145/3626772.3657716.

[6] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, ``BPR: Bayesian Personalized Ranking from Implicit Feedback," in *Proceedings of UAI*, 2009.

[7] S. Yoo and J. Kim, ``Merchant Recommender System Using Credit Card Payment Data," *Electronics*, vol. 12, no. 811, 2023, doi: 10.3390/electronics12040811.

[8] E. Yilmaz, M. K. Turgut, and S. Ayday, ``A Link Prediction-Based Recommendation System Using Transactional Data," *Scientific Reports*, vol. 13, 2023.

[9] R. van den Berg, T. N. Kipf, and M. Welling, ``Graph Convolutional Matrix Completion," *KDD Workshop on Deep Learning for Recommender Systems*, 2018, arXiv:1706.02263.

[10] I. Sukharev, V. Shumovskaia, K. Fedyanin, M. Panov, and D. Berestnev, ``EWS-GCN: Edge Weight-Shared Graph Convolutional Network for Transactional Banking Data," *IEEE ICDM Workshop*, 2020, arXiv:2009.14588.

[11] V. Shumovskaia, N. Fedyanin, I. Sukharev, D. Berestnev, and M. Panov, ``Linking Bank Clients Using Graph Neural Networks Powered by Rich Transactional Data," *International Journal of Data Science and Analytics*, 2021, doi: 10.1007/s41060-021-00276-w.